

Prediction of Restaurant Price Range Using Supervised Machine Learning Techniques

Wallan De Melo Lima¹, Helder Seixas Lima²

¹Instituto de Informática – Instituto Federal Do Norte De Minas Gerais - Campus
Januária (IFNMG)
Caixa Postal 39.480-000 – Januária – MG – Brazil

Abstract. *This paper presents the application of supervised machine learning techniques to predict the price range of restaurants based on attributes such as location, cuisine type, customer ratings, and offered services. A real-world dataset was used to model a multiclass classification problem. Four algorithms were evaluated: Logistic Regression, K-Nearest Neighbors, Decision Tree, and Random Forest. The models were compared using standard classification metrics, including accuracy, precision, recall, F1-score, and confusion matrix. The results indicate that tree-based models, particularly Random Forest, achieved superior performance and better generalization capability.*

Resumo. *Este trabalho apresenta a aplicação de técnicas de Aprendizado de Máquina supervisionado para a previsão da faixa de preço de restaurantes a partir de características como localização, tipo de culinária, avaliações dos clientes e serviços oferecidos. Utilizou-se um conjunto de dados real, caracterizando um problema de classificação multiclasse. Foram avaliados os algoritmos Regressão Logística, K-Nearest Neighbors, Árvore de Decisão e Random Forest. A comparação foi realizada por meio de métricas clássicas de classificação, como acurácia, precisão, recall, F1-score e matriz de confusão. Os resultados indicaram melhor desempenho dos modelos baseados em árvores, com destaque para o Random Forest.*

1. Introdução

O avanço das técnicas de Aprendizado de Máquina tem possibilitado o desenvolvimento de sistemas capazes de apoiar a tomada de decisão em diferentes áreas do conhecimento, incluindo o setor gastronômico. A análise automatizada de dados relacionados a restaurantes permite extrair informações relevantes sobre padrões de consumo, avaliações de clientes e posicionamento de mercado. Nesse contexto, a previsão da faixa de preço de estabelecimentos gastronômicos, a partir de características observáveis, pode ser útil tanto para consumidores quanto para gestores, auxiliando na análise de mercado e no planejamento estratégico.

Dessa forma, este trabalho tem como objetivo aplicar e comparar diferentes algoritmos de classificação supervisionada para a previsão da faixa de preço de restaurantes, utilizando um conjunto de dados reais disponibilizado publicamente. O estudo busca avaliar o desempenho de modelos amplamente utilizados na literatura, analisando métricas clássicas de classificação e a capacidade de generalização de cada abordagem, de modo a identificar o algoritmo mais adequado para o problema proposto.

2. Metodologia

A metodologia adotada neste trabalho segue as etapas clássicas de um projeto de Aprendizado de Máquina supervisionado, compreendendo o pré-processamento dos dados, a análise exploratória, a definição das variáveis de entrada e saída, o treinamento dos modelos e a avaliação dos resultados obtidos.

A base de dados utilizada contém informações detalhadas sobre restaurantes, incluindo localização geográfica, tipo de culinária, avaliações dos clientes, serviços oferecidos e faixa de preço. A variável alvo definida foi a coluna *Price range*, que representa diferentes níveis de custo e caracteriza o problema como uma tarefa de classificação multiclasse.

Na etapa de pré-processamento, realizou-se a conversão de variáveis categóricas binárias em valores numéricos, bem como a codificação de variáveis categóricas nominais por meio da técnica de *one-hot encoding*. Em seguida, o conjunto de dados foi particionado em dois subconjuntos: 80% dos registros foram destinados ao treinamento dos modelos e 20% à fase de teste, preservando-se a proporção das classes da variável alvo.

Para algoritmos sensíveis à escala dos dados, como a Regressão Logística e o K-Nearest Neighbors (KNN), aplicou-se a padronização das variáveis numéricas utilizando o método *StandardScaler*, garantindo que todas as características contribuíssem de forma equilibrada no processo de treinamento.

Os modelos de classificação selecionados para este estudo foram: Regressão Logística Multiclasse, K-Nearest Neighbors (KNN), Árvore de Decisão e Random Forest. Esses algoritmos foram escolhidos por apresentarem diferentes níveis de complexidade, interpretabilidade e desempenho em problemas de classificação.

3. Resultados

A avaliação do desempenho dos modelos foi realizada por meio de métricas clássicas de classificação, incluindo acurácia, precisão, recall, F1-score e matriz de confusão. Essas métricas possibilitaram uma análise comparativa detalhada entre os algoritmos, considerando tanto o desempenho global quanto o comportamento em cada classe da variável alvo.

Os resultados obtidos indicaram que os modelos baseados em árvores apresentaram desempenho superior em relação aos demais, com destaque para o algoritmo Random Forest, que alcançou maior acurácia e melhor equilíbrio entre precisão e recall nas diferentes faixas de preço. Esse comportamento sugere uma maior capacidade do modelo em capturar relações não lineares presentes nos dados.

A análise da matriz de confusão evidenciou que os principais erros de classificação ocorreram entre faixas de preço adjacentes, indicando que o modelo tende a confundir restaurantes com níveis de custo semelhantes. Esse resultado é esperado em conjuntos de dados reais, nos quais a separação entre classes próximas pode ser menos evidente.

Link do Colab:

<https://colab.research.google.com/drive/1N5qdWfp8Cn8P2-HTXPbp7jWMnLxutlUJ?usp=sharing>

Análise dos Resultados e Métricas de Avaliação

Foram avaliados quatro modelos de classificação supervisionada: Regressão Logística, K-Nearest Neighbors (KNN), Árvore de Decisão e Random Forest, utilizando as métricas acurácia, precisão, recall, F1-score e matriz de confusão.

1. Regressão Logística

- Acurácia: $\approx 71,6\%$
- Apresentou desempenho razoável para as classes de menor faixa de preço (classe 1), porém queda significativa nas classes mais altas.
- O recall da classe 4 (0,38) indica dificuldade do modelo em identificar corretamente restaurantes de maior faixa de preço.
- O F1-score médio ponderado (0,71) reflete um desempenho limitado para um problema com fronteiras de decisão não lineares.

A Regressão Logística, por ser um modelo linear, apresenta limitações para capturar padrões complexos presentes nos dados, especialmente em classes com menor representatividade.

2. K-Nearest Neighbors (KNN)

- Acurácia: $\approx 67,9\%$
- Desempenho inferior em relação à Regressão Logística.
- Forte queda nas métricas conforme aumenta a faixa de preço:
 - Classe 4 apresentou recall de apenas 0,27.
- O F1-score macro (0,56) indica dificuldade geral em equilibrar precisão e recall entre todas as classes.

O KNN é sensível à dimensionalidade elevada causada pelo one-hot encoding (City e Cuisines), o que prejudica o cálculo de distâncias e impacta negativamente o desempenho.

3. Árvore de Decisão

- Acurácia: $\approx 96,9\%$
- Excelente desempenho em todas as classes.
- Recall de 1.00 na classe 1, indicando identificação perfeita dessa categoria.
- F1-score macro (0,94) mostra equilíbrio entre as métricas mesmo em classes minoritárias.

A Árvore de Decisão consegue capturar relações não lineares e interações entre variáveis, sendo altamente eficaz neste tipo de conjunto de dados. No entanto, pode estar sujeita a overfitting, o que deve ser analisado com a validação cruzada.

4. Random Forest

- Acurácia: $\approx 93,6\%$
- Desempenho muito elevado e consistente.

- Excelente equilíbrio entre precisão e recall nas classes 1 e 2.
- Classe 4 apresentou recall de 0,64, indicando ainda alguma dificuldade, porém melhor generalização que modelos mais simples.
- F1-score ponderado (0,93) confirma a robustez do modelo.

O Random Forest apresentou o melhor equilíbrio geral, reduzindo o risco de overfitting observado em árvores individuais e mantendo alta capacidade de generalização.

Análise da Matriz de Confusão

A matriz de confusão do Random Forest indica que:

- Os principais erros de classificação ocorrem entre faixas de preço adjacentes.
- Isso demonstra que o modelo tende a confundir restaurantes com características semelhantes, o que é esperado em cenários reais.
- Não há confusões extremas (ex.: classe 1 sendo prevista como classe 4), o que reforça a qualidade do modelo.

Os resultados demonstram que modelos baseados em árvores, especialmente o Random Forest, são mais adequados para a previsão da faixa de preço dos restaurantes. Eles apresentam maior capacidade de capturar padrões complexos, melhor equilíbrio entre precisão e recall e maior robustez frente à variabilidade dos dados.

Esses achados reforçam a escolha do Random Forest como o modelo final do estudo e justificam sua superioridade frente a modelos lineares e baseados em distância.

4. Conclusão

Este trabalho apresentou a aplicação de técnicas de Aprendizado de Máquina supervisionado para a previsão da faixa de preço de restaurantes, utilizando dados reais e diferentes algoritmos de classificação. A abordagem adotada permitiu comparar o desempenho dos modelos e analisar sua capacidade de generalização a partir de métricas consolidadas na literatura.

Os resultados demonstraram que modelos mais robustos, como o Random Forest, são mais adequados para esse tipo de problema, apresentando melhor desempenho global e maior estabilidade na classificação das diferentes faixas de preço.

5. References

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. Springer, 2009.

PEDREGOSA, F. et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 2011.

KAGGLE. *Restaurant Dataset*. Disponível em: <https://www.kaggle.com>

CASTRO, Leandro Nunes de; FERRARI, Daniel Gomes. Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, v. 5, p. 1-376, 2016.

Mohammed J. Zaki, Wagner Meira, Jr., *Data Mining and Machine Learning: Fundamental Concepts*

and Algorithms, 2nd Edition, Cambridge University Press, March 2020. ISBN: 978-1108473989.

<https://dataminingbook.info/>