



**INSTITUTO
FEDERAL**

Norte de Minas Gerais

Campus
Januária

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO FINAL - Parte 01

Equipe técnica:

Wallan De Melo Lima

Trabalho Final como
parte de obtenção de
nota para a disciplina
de Sistemas De Apoio
à Decisão.

Orientador: Prof.
Helder Seixas Lima

Januária MG

2026



**INSTITUTO
FEDERAL**

Norte de Minas Gerais

Campus
Januária

BACHARELADO EM SISTEMAS DE INFORMAÇÃO

TRABALHO FINAL - Parte 01

Januária MG

2026

Parte 1 - Proposta do Trabalho

1. Objetivo Geral do Trabalho

O objetivo geral deste trabalho é desenvolver e avaliar modelos de aprendizado de máquina supervisionado aplicados a um problema de classificação, com a finalidade de prever a faixa de preço dos restaurantes do dataset a partir de características relacionadas à localização, tipo de culinária, serviços oferecidos e avaliações dos clientes. O estudo busca comparar o desempenho de diferentes algoritmos de classificação e analisar a influência das variáveis explicativas na definição da faixa de preço, contribuindo para a tomada de decisão no setor gastronômico.

2. Tipo do Problema

O problema abordado neste trabalho é do tipo classificação supervisionada multiclasse, uma vez que a variável alvo assume valores discretos que representam diferentes faixas de preço.

3. Descrição da Base de Dados Utilizada

A base de dados utilizada neste trabalho é um conjunto de dados disponibilizado na plataforma Kaggle, contendo informações detalhadas sobre 500 restaurantes.

Visão Geral

Este conjunto de dados contém informações detalhadas sobre 500 restaurantes, selecionadas para apoiar projetos de análise de dados, visualização e aprendizado de máquina. Ele foi desenvolvido para estudantes, pesquisadores e profissionais que desejam explorar insights relacionados a restaurantes, como preferências culinárias, distribuição de custos, avaliações e tendências baseadas em localização.

Detalhes do Conjunto de Dados

- Número de registros: 500
- Atributos abordados:
-  Nome do restaurante – Identidade única de cada restaurante

- 📍 Localização/Cidade – Posicionamento geográfico para análise regional
- 🍴 Tipo(s) de culinária – Culinária principal e secundária oferecidas
- ★ Classificações – Avaliações de clientes (numéricas ou categóricas)
- 💰 Custo médio para duas pessoas – Preços indicativos para análise de acessibilidade
- 🕒 Horários – Horário de abertura e fechamento
- 📞 Informações de contato – Números de telefone ou presença online (se disponíveis)
- 📁 Recursos adicionais – Opções de entrega, disponibilidade de assentos, etc.

🎯 Finalidade do conjunto de dados

Este conjunto de dados pode ser usado para:

- Análise Exploratória de Dados (AED): Identificar a popularidade da culinária, a distribuição de custos e as tendências de avaliação.
- Projetos de Visualização: Criar painéis que mostrem avaliações de restaurantes, custos e diversidade culinária.
- Modelos de Aprendizado de Máquina:
- Preveja a classificação de restaurantes com base em suas características.
- Classifique os restaurantes por tipo de culinária ou faixa de preço.
- Recomendar restaurantes usando abordagens baseadas em similaridade.
- Análises de Negócios: Ajude empreendedores e plataformas de entrega de comida a entender as tendências de mercado.

🌐 Casos de Uso

- Compare os preços dos restaurantes em diferentes cidades.
- Analise quais culinárias são mais populares em regiões específicas.
- Crie um sistema de recomendação para usuários com base em suas preferências.
- Estudar a correlação entre avaliações e custos.

✅ Pontos-chave

- O conjunto de dados foi limpo e estruturado para facilitar o uso.
- Indicado para iniciantes (análise básica) e usuários avançados (modelagem preditiva).
- Pode ser integrado em Python (pandas, matplotlib, seaborn) ou em ferramentas de BI (Power BI, Tableau) para visualização.

Link da Base de Dados:

<https://www.kaggle.com/datasets/sayan20004/5000-restaurant-dataset-all-details>

4. Definição da Variável Alvo

A variável alvo definida para o problema é a coluna Price range, que representa a faixa de preço dos restaurantes. Essa variável é categórica e assume valores discretos que indicam diferentes níveis de custo, permitindo sua utilização direta em um problema de classificação multiclasse.

5. Definição dos Conjuntos de Treino e Teste

O conjunto de dados será dividido em dois subconjuntos distintos:

- **Conjunto de treino:** 80% dos dados
- **Conjunto de teste:** 20% dos dados

A divisão será realizada de forma aleatória, preservando a proporção das classes da variável alvo, de forma a garantir uma avaliação justa do desempenho dos modelos.

6. Estratégia ou Método de Treinamento dos Modelos

Inicialmente, será realizada uma etapa de pré-processamento dos dados, que inclui a limpeza do dataset, o tratamento de valores ausentes e a codificação de variáveis categóricas, como cidade e tipo de culinária.

Os modelos serão treinados utilizando aprendizado supervisionado, com divisão dos dados em conjuntos de treino e teste, permitindo a avaliação do desempenho em dados não vistos.

7. Algoritmos de Predição Selecionados

Para a realização deste trabalho, serão utilizados e comparados os seguintes algoritmos de classificação:

- **Regressão Logística Multiclasse**
- **K-Nearest Neighbors (KNN)**
- **Árvore de Decisão**
- **Random Forest**

Esses algoritmos foram selecionados por sua ampla utilização em problemas de classificação e por apresentarem diferentes níveis de complexidade e interpretabilidade.

8. Métricas e Métodos para Avaliação dos Resultados

A avaliação do desempenho dos modelos será realizada por meio das seguintes métricas:

Acurácia

A acurácia mede e avalia a proporção total de previsões corretas realizadas pelo modelo em relação ao número total de instâncias avaliadas.

Contextualizando

Quando aplicada no contexto do problema indica quantos restaurantes tiveram sua faixa de preço corretamente prevista, considerando todas as classes, por exemplo, se a acurácia for 0,85, significa que o modelo acertou 85% das faixas de preço.

Precisão (Precision)

A precisão mede, entre todas as previsões feitas para uma determinada classe, quantas realmente pertencem a essa classe.

Contextualizando

Avalia quão confiável é o modelo ao prever uma determinada faixa de preço. Por exemplo: quando o modelo diz que um restaurante é de faixa alta, quantas vezes isso está correto?

Recall

O recall mede a capacidade do modelo de identificar corretamente todos os exemplos reais de uma classe.

Contextualizando

Indica quantos restaurantes de uma determinada faixa de preço foram corretamente identificados pelo modelo.

F1-score

O F1-score é a média harmônica entre precisão e recall, fornecendo uma medida equilibrada entre ambos.

Contextualizando

É especialmente útil para avaliar o desempenho do modelo quando há desequilíbrio entre as classes de faixa de preço, pois considera simultaneamente erros por excesso e por falta.

Matriz de Confusão

A matriz de confusão apresenta de forma detalhada:

- As previsões corretas
- E os erros de classificação entre as classes

Contextualizando

Permite identificar:

- Quais faixas de preço são mais confundidas entre si
- Se o modelo tende a superestimar ou subestimar o preço dos restaurantes

Essas métricas permitirão comparar o desempenho dos modelos e analisar os erros de classificação entre as diferentes faixas de preço.

9. Análise Descritiva Inicial dos Dados

Na etapa inicial, será conduzida uma **análise descritiva e exploratória dos dados**, com o objetivo de compreender o comportamento das variáveis e identificar padrões relevantes.

Essa análise incluirá:

- Distribuição das faixas de preço dos restaurantes
- Análise do custo médio para duas pessoas
- Relação entre avaliações (*Aggregate rating* e *Votes*) e faixa de preço
- Frequência dos tipos de culinária e serviços oferecidos

Gráficos e estatísticas descritivas serão utilizados para apoiar a compreensão dos dados e orientar a etapa de modelagem.